



An Adaptive Cold-Aware Recommendation System for Sparse E-Commerce Data

**RecLM-RAG : Pipeline RAG Zero-Shot sans
Entraînement**

Assia Bouamir, Assoumana Souley Hadiza, Yassine Afoudi

Laboratoire d'Informatique et Systèmes Intelligents (LISI)
Faculté des Sciences Semlalia, Université Cadi Ayyad (UCA), Marrakech, Maroc

Présentation pour la Conférence ICCS C 2026 | IEEE

Plan de la Présentation

01**Motivation & Défis****02****Cadre RecLM-RAG****03****Composants Clés****04****Résultats Expérimentaux****05****Cold-Start & Ablation****06****Contributions & Perspectives**

Motivation : La Réalité du E-commerce en 2025

Les systèmes de recommandation génèrent 30 à 40 % du chiffre d'affaires sur Amazon et Alibaba

Pourtant, plus de 80 % des déploiements industriels reposent encore sur la factorisation de matrices (SVD, ALS) et le filtrage collaboratif par voisinage, qui peinent face à :



Problème du Cold-Start :

68–75 % des sessions n'ont aucun historique utilisateur → aucune recommandation



Décisions Opaques :

Boîte noire → fatigue utilisateur, CTR moyen de seulement 1,7 %



Pas de Langage Naturel :

Impossible de traiter des requêtes comme « sacs vegan sous 50 € durables »



Absence de Signaux Éthiques :

Ignore la demande croissante de durabilité et de transparence

Notre Solution : RecLM-RAG

Un framework RAG (Retrieval-Augmented Generation) entièrement zero-shot et sans entraînement qui transforme la recommandation produit en un processus conversationnel, transparent et sensible à la durabilité.



Récupération Sémantique



Score de Durabilité



Re-classement LLM



Native Cold-Start

RecLM-RAG : Pipeline en 6 Étapes (Sans Entraînement)

1

Encodage Entrée

BGE-Large (1024d)
Requête ou historique → embedding

2

Recherche Vectorielle

FAISS IVF4096-HNSW32-PQ64
Top-100 candidats (<15 ms)

3

Score Durabilité

Scoreur basé règles
Mots-clés + régression (0–100)

4

Construction Prompt

Requête + historique + candidats
+ objectif durabilité

5

Re-classement LLM

Llama-3.1-8B
Sortie JSON zero-shot

6

Sortie Finale

Top-10 avec explications
+ scores de durabilité

Toutes les étapes sont sans entraînement et zero-shot. Latence end-to-end ≈ 1,1 s sur un seul GPU A100.

Protocole Expérimental

Jeux de données : Amazon Reviews 2018 (Electronics & Clothing, Shoes & Jewelry)

Statistique	Electronics	Clothing & Jewelry
Nombre d'utilisateurs	192 403	278 154
Nombre d'articles	63 001	85 547
Nombre d'interactions	7 824 482	5 748 292
Sparsité	99,94 %	99,88 %
Moy. articles/utilisateur	40,7	20,7

Protocole d'Évaluation

- Split temporel leave-one-out (entraînement sur tout sauf les 7 derniers jours, test sur le dernier jour)
- Jeu de test cold-start : 10 000 utilisateurs avec ZÉRO historique d'interaction
- Métriques : Recall@10, NDCG@10, Diversité@10 (distance cosinus moyenne), Ratio Long-Tail
- Baselines : Popularity, SVD, LightGCN, SASRec, P5 (few-shot)
- Matériel : 1× NVIDIA A100 80 Go, PyTorch 2.1, FAISS-GPU 1.8.0

Résultats Principaux sur Amazon Reviews 2018

Meilleurs résultats en gras. † = significativement supérieur au meilleur baseline (P5) à $p < 0,01$

Méthode	R@10	NDCG@10	Div@10	LT (%)	Lat. (ms)
Popularity	0.189	0.312	0.21	4.2	8
SVD	0.256	0.378	0.29	8.7	12
LightGCN	0.341	0.456	0.38	14.3	45
SASRec	0.367	0.471	0.41	16.8	68
P5 (few-shot)	0.398	0.489	0.47	19.4	890
RecLM-RAG (Llama)	0.498†	0.562†	0.71†	38.4†	1 100
RecLM-RAG (Mixtral)	0.514†	0.579†	0.73†	41.2†	1 340

+25,1 %

Recall@10 vs P5

+51,1 %

Diversité@10 vs P5

+98 %

Couverture Long-Tail

Performances en Cold-Start

Les modèles CF traditionnels et profonds chutent au niveau de la baseline Popularity ($R@10 \approx 0,19$) sans historique.

RecLM-RAG conserve 92,6 % du Recall@10 warm-start en cold-start pur (0,461 vs 0,498 avec Llama sur Electronics)
et 90,1 % sur Clothing — en utilisant uniquement les embeddings de requête et les métadonnées d'articles.

Points Clés en Cold-Start

- ✓ Mixtral améliore encore le Recall cold-start à 0,478 (meilleur raisonnement zero-shot)
- ✓ Les requêtes plus longues (> 50 tokens) donnent +15 % de Recall en cold-start
- ✓ Le matching sémantique par requête + raisonnement LLM remplace le graphe d'interactions manquant
- ✓ Conforme aux résultats de Sanner et al. (RecSys 2023) : les LLM sont compétitifs en near cold-start zero-shot

Étude d'Ablation (Electronics, Llama-3.1-8B)

Variante	NDCG@10	Δ	Div@10	Δ
RecLM-RAG complet	0.562	—	0.71	—
Sans module durabilité	0.548	−2,5 %	0.68	−4,2 %
Sans historique utilisateur dans le prompt	0.519	−7,7 %	0.70	−1,4 %
Top-50 au lieu de Top-100	0.541	−3,7 %	0.69	−2,8 %
BGE-Base au lieu de BGE-Large	0.512	−8,9 %	0.66	−7,0 %
Sans re-classement LLM (FAISS seul)	0.472	−16,0 %	0.62	−12,7 %

Enseignements Clés

- Le re-classement LLM apporte le gain le plus important (−16 % NDCG sans lui) — le raffinement génératif est crucial
- Le module de durabilité agit comme un prior domaine-spécifique efficace (+2,5 % NDCG, +4,2 % diversité)
- Les embeddings BGE-Large contribuent +8,9 % par rapport à la variante plus petite — la qualité sémantique compte

Contributions Principales

1

Pipeline RAG zero-shot et sans entraînement

Intègre conjointement des signaux éthiques et de la recommandation produit explicable, sans aucun backbone CF ni fine-tuning.

2

Intégration explicite de la durabilité

Module de scoring léger et temps réel directement intégré dans la boucle récupération-génération (validé $r=0,74$ vs notes éco).

3

Résultats empiriques solides sur benchmark public

+25,1 % Recall@10, +14,9 % NDCG@10, +51,1 % Diversité@10, +98 % Long-Tail vs meilleur baseline (P5), avec code open-source reproductible.

4

Solution pratique pour le cold-start

Conserve 92,6 % des performances warm-start pour les utilisateurs sans historique via matching sémantique + raisonnement LLM.

Limites et Travaux Futurs

Limites Actuelles

- ⚠ Latence 1,1–1,3 s acceptable pour le web mais élevée pour le mobile temps réel (LLM = 91 % du coût)
- ⚠ Lexique de durabilité validé uniquement sur Electronics/Clothing ; nécessite extension par domaine
- ⚠ Hallucinations occasionnelles (< 5 %) ; le grounding par récupération aide mais n'élimine pas le problème
- ⚠ Aucune utilisation des images produits (opportunité multimodale)

Latence projetée avec décodage spéculatif sur GPU H200 : moins de 500 ms end-to-end

Conclusion

RecLM-RAG démontre qu'un pipeline RAG soigneusement conçu et sans entraînement peut surpasser les filtrages collaboratifs traditionnels et profonds tout en offrant trois propriétés rarement combinées :

- ✓ Capacité zero-shot — aucun entraînement ni fine-tuning sur le domaine cible
- ✓ Explicabilité en langage naturel — justifications lisibles par l'humain en anglais/français
- ✓ Sensibilisation explicite à la durabilité — signaux éthiques dans chaque recommandation
- ✓ Résolution efficace du cold-start — 92,6 % de rétention des performances warm-start sans historique

En montrant qu'une recommandation performante et éthique est possible sans entraînement de modèle, RecLM-RAG ouvre la voie à des systèmes d'IA responsables qui alignent excellence technique et valeurs sociétales.

Merci

Questions & Discussion



Code, modèles et démo

https://github.com/ASSIAbouamir/Rec_Sys.git

Démo Gradio + API Docker prête pour déploiement

Assia Bouamir • a.bouamir8225@uca.ac.ma • Laboratoire LISI, UCA Marrakech